

Machine Learning

313707071_Assignment 11

一、Unanswered Questions 總結

問題 1：MLP 近似 Runge 函數 $f(x)$ 與導數 $f'(x)$

Question: 如果要求「在整個區間內同時控制 $\|f - \hat{f}\|_\infty$ 與 $\|f' - \hat{f}'\|_\infty$ 都小於某個門檻」

1. 同時考慮函數本身與函數導數的 loss:

$$L = \lambda_{f(x)} L_{f(x)} + \lambda_{f'(x)} L_{f'(x)}$$

調整權重 λ 能平衡兩者的貢獻度

2. 如何在曲率變化大的區域放更多樣本點

類似的想法已經在 PINN 中被廣泛研究，常透過 residual 或梯度大小來做自適應取樣，讓網路在「變化劇烈的區域」放更多點。

Mao, Z., & Meng, X. (2023). Physics-informed neural networks with residual/gradient-based adaptive sampling methods for solving partial differential equations with sharp solutions. *Applied Mathematics and Mechanics*, 44(7), 1069-1084.

- ✓ 這篇針對具有尖銳解的 PDE，提出了基於殘差與梯度的自適應取樣方法（ASMI、ASM II）來改善 PINN 的表現。不只看殘差大，也看梯度大，並在這些地方加入新點。

問題 2：GDA/QDA 在高維的可靠性

Question: 如果之後想把氣候資料升維（例如加入高度、時間、地形特徵等變成 20 維特徵），但仍然想用 QDA 在樣本數固定的情況下，對 Σ_k 做 MLE 會遇到哪些數值或統計上的風險？

- ：每一類的樣本數如果跟維度差不多，甚至更少， Σ_k 會「秩不足」或「很接近奇異」，且反矩陣 Σ_k^{-1} 很難算、很不穩定。

Lam, C. (2020). High-dimensional covariance matrix estimation. *Wiley Interdisciplinary reviews: computational statistics*, 12(2), e1485.

- ✓ 近年的 review 指出，在高維情境下，未正則化的樣本協方差幾乎總是

病態或不可逆，因此必須採用 shrinkage 或稀疏化等方法。

問題 3：Piecewise smooth function

$$h(\vec{x}) = \begin{cases} R(\vec{x}) & \text{if } C(\vec{x}) = 1 \\ -999 & \text{if } C(\vec{x}) = 0 \end{cases}$$

先用分類器決定「要不要預測」，再用線性迴歸給溫度。

Question: 這種「兩階段、硬切換」的設計，在理論上會帶來什麼樣的偏差或錯誤傳遞？（例如：分類錯誤導致迴歸永遠沒有機會被訓練到某些區域）。

：兩階段架構，會把訓練資料限制在一個經過選擇機制而偏斜的子集合上，導致迴歸模型只在被選中的區域學習、對被排除區域完全失明。

Geifman, Y., & El-Yaniv, R. (2019, May). Selectivenet: A deep neural network with an integrated reject option. In *International conference on machine learning* (pp. 2151-2159). PMLR.

✓ 這篇把「要不要預測（reject option / selective prediction）」跟預測本身一起 end-to-end 訓練，避免像現在這種先硬切再回歸、無法把最終誤差回傳到 selection 模組的問題。

問題 4：Score Matching / Diffusion 模型的「識別性」與「可反推性」

Question:

對於一個用 DSM + SDE 訓練出來的 score-based model：

是否存在「不同的真實分佈」卻對應到幾乎一樣的 score，導致我們即使學會了 score 也「無法唯一決定」底層分佈？

：從「正確的 score」理論上可以唯一恢復底層密度。

問題 5: DSM 在未來扮演什麼角色

：Denoising Score Matching 本身是 score-based / diffusion 模型的一個核心理論工具，短期內不太可能被完全取代，但在發展上確實面臨計算成本高、主要適用於連續資料，以及只能學到 score 而非完整密度等限制；因此，近年的研究多傾向用 flow matching、consistency models 等替代表述來改善效率與易用性，讓 DSM 逐漸退居「理論基礎」而非直接出現在方法名稱的第一線。

二、 20 年後的 AI

1. 預期它能做到的事

- I. 有 70%做大腸內視鏡的人，都沒有發現任何問題，頂多只有增生息肉。因此，我預期未來 AI 應該要能做到在選擇照內視鏡前，利用健檢資料、電子健康紀錄(EHR)、家族史、或相關檢驗數值，預測未來發生大腸癌的機率。並且 AI 每年幫助人們算「未來 5-10 年罹患大腸癌或存在進展性腺瘤 (Advanced adenoma) 的風險」，高風險的人自動被系統提醒去做糞便潛血或大腸鏡。
- II. 由於民眾都希望得到最好的醫療資源，即使不是很嚴重的病症，也希望到大醫院就診，使得教學醫院的專業醫師無法將醫療量能提供給真正需要的人，因此，AI 能夠學習專業經驗，在地方醫院輔助醫師辨別是否該進一步就診，如此能使大小醫院都有可靠的專業水平，也能妥善運用醫療量能。

2. 對人類社會的效益

1. 透過預測，使人們不必對潛在的病症過於憂心，同時避免浪費醫療資源。
2. AI 進入地區醫院，讓真正亟需專業治療的人能獲得資源

3. 大方向重述

用健檢 / 門診的日常資料，預測一個人未來幾年得到進展性大腸腫瘤 (advanced colorectal neoplasia, ACN) 或大腸癌的風險，讓高風險的人比較早做大腸鏡，進行比較密集檢查，低風險的人可以拉長間隔。此外，如何讓 AI 學習判斷切片影像，知識移轉，是第二部分要探討的問題。

4. 簡化模型問題

用『一次健檢』的少數特徵 (例如年齡、性別、BMI、家族史、抽菸) 去預測「這次大腸鏡是否有進展性腫瘤 (ACN)」的機率，建立一個校正良好、可解釋的風險模型，並給出「高風險門檻」做為是否安排大腸鏡的簡單決策規則。

Input/Output

$$x_i = [Age_i, Sex_i, BMI_i, FH_i, Smoking_i]$$

Age：年齡 (連續)

Sex：性別（0 = 女, 1 = 男）

BMI：體重指數（連續）

FH (family history)：是否有一等親大腸癌（0/1）

Smoking：是否抽菸（0/1）

$$y_i = \begin{cases} 1, & \text{此人這次大腸鏡有 ACN / CRC} \\ 0, & \text{沒有} \end{cases}$$

Hypothesis: Logistic regression

$$\hat{p}_i = h_{\theta}(x_i) \approx P(Y = 1 | X = x_i)$$

$$h_{\theta}(x) = \sigma(\theta^T \tilde{x}) = \sigma(\theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_3 + \theta_4 x_4 + \theta_5 x_5)$$

$$\hat{p} = \frac{1}{1 + e^{-(\theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_3 + \theta_4 x_4 + \theta_5 x_5)}}$$

$\hat{p}$: 預測 $y = 1$ 的機率

$\theta_0, \theta_1, \theta_2, \theta_3, \theta_4, \theta_5$: 模型學習之參數

x_1, x_2, x_3, x_4, x_5 : 特徵輸入 (x_1 : Age, x_2 : Sex, x_3 : BMI, x_4 : FH, x_5 : Smoking)

Loss function: Cross-entropy

$$Loss = -y \ln h_{\theta}(x) - (1 - y) \ln(1 - h_{\theta}(x))$$

$$y \in \{0, 1\}, h_{\theta}(x) = \hat{p}$$

如果以上順利做出來，進行第二部分

假設：

A. 原始標註 = 專家標註（ground truth）。

B. 「人為加噪音」模擬地區醫院醫師的誤判（例如把 10–20% 標籤故意改錯）

給定一組大腸鏡影像與「高品質專家標籤」，訓練一個模型 f_{θ} 來預測病灶是否為腺瘤 / 高風險病灶（專家級判讀）。接著，在一組「含有噪音標籤」的模擬地區醫院資料上，檢驗 f_{θ} 是否能比「噪音標籤」更接近專家真實標籤，以此做為「AI 幫助地區醫院醫師接近教學醫院水準」的第一個證明。